QoE Data 를 이용한 이상감지

2019.01.15

인턴 김지희, 장예훈

INISOFT

Project Instruction

Project Instruction

프로젝트 목적

QoE Data 패턴 분석을 통해 주기적으로 발생하는 에러를 예측하고 분류하여 최종적으로 에러의 원인을 신속하게 파악할 수 있도록 함

프로젝트 기간

2018.11.28 - 2019.1.14

프로젝트 과정

1. QoE 및 데이터 분석 Tool 사전조사
2. Data 수집
3. Feature Engineering
4. 실험
    a. Resampling
    b. SMOTE
    c. Decision Tree
    d. Random Forest

5. 문서화 및 발표

QoE Data Description

QoE Data Description

Data Details

2018.11.06 00:00 - 2018.11.07 23:59 (2일)
s3 , qoe-dtv

Event 별 분류

QoE Event	설명	
PlaybackStarted	Playback session 이 시작될 때의 event	본 프로젝트에서 사용하지 않음
PlaybackUpated	Playback session이 시작되고 끝나기 전까지 1분 간격으로 발생하는 event	X , 독립변수
PlaybackEnded	Playback session 종료 시 발생하는 event . 정상 종료시 errorcode == 0, error 발생 시 12가지 종류의 errorCode 수반	X, errorCode : Y

QoE Data Description

Field Name	Playback Updated	Playback Ended
sessionId	O	O
bufferedDuration	O	
bufferings	O	
configurations		
contentUrl	O	O
currentPosition	O	
device	O	O
device.*	O	O
duration		
status		
timestamp	O	O

	Playback Updated	Playback Ended
errorCode		O
errorString		O
estimatedBandwidth	O	
event	O	O
fragmentSum.*	O	
fragments	O	
frameDropped	O	
licenseInfo.*	O	O
maxDecodingTime	O	
tracks		
userEvents	O	

	Playback Updated	Playback Ended
networkChanged	O	
networkErrors	O	
networkInfo.*	O	O
position		O
qoeContentId	O	O
qualityChanged	O	
redirectUrl	O	O
avgDecodingTime	O	
startupTime		
userInfo		

QoE Data Description

Data Merging Rule

sessionId	event	time stamp	C	D	E	F	G
123	playbackEnded	15632	c	d	e	f	g

sessionId	event	timest amp	C	D	K	L	M
123	playbackUpdated	15000	c	d	k	f	g
123	playbackUpdated	15123	a	d	b	e	g
123	playbackUpdated	15345	d	a	m	d	h
198	playbackUpdated	15589	t	j	f	n	m

sessionId	timestamp	C	D	E	F	G	K	L	M
123	15632	c	d	e	f	g	m	d	h

Feature Selection

Features Selection

1) Invalid Feature 삭제

A) Too Sparse Column

```
In [2]: rdf = pd.read_pickle('data/concated_all_1.pkl')
        rdf.shape, rdf.columns
Out[2]: ((25050, 39),

In [14]: len(rdf['deviceInfo.deviceId'].value_counts())
Out[14]: 5566
```

총 25050개의 data 중 5566개의 카테고리 생성 시 **data의 분포가 너무 희박해져 학습에 악영향**

+ qoeContentId 동일한 문제로 삭제

B) Duplicated Column

```
In [22]: rdf.iloc[1]['deviceInfo.os']
Out[22]: 'Android'

In [23]: rdf.iloc[1]['deviceInfo.osVersion']
Out[23]: '7.0'

In [25]: rdf.iloc[1]['device']
Out[25]: 'Android 7.0'
```

하나의 column 에서 파생된 column에 대하여 가장 많은 정보를 포함한 column을 남기고 삭제

C) Meaningless Column

```
In [16]: rdf['licenseInfo.laUrl'].value_counts()
Out[16]: https://app.video.dmkt-sp.jp/license/widevine-challenge    21309
         NaN                                                           1
         Name: licenseInfo.laUrl, dtype: int64
```

모든 data에 같은 값이 매핑되어있는 column은 의미가 없어서 삭제

+ deviceInfo.player,
  networkChanged
  networkInfo.carrier.name
  fragments .etc 삭제

Features Selection

2) pearson 상관관계 분석 결과

avgDecodingTime	0.070473
bufferedDuration	0.041627
currentPosition	0.126110
device	-0.018956
errorCode	1.000000
estimatedBandwidth	0.072219
fragmentSum.bitrate	0.051129
fragmentSum.downloadTime	0.011791
fragmentSum.duration	0.011543
fragmentSum.fragmentIndex	-0.005489
fragmentSum.size	0.048179
frameDropped	0.021447
licenseInfo.drmSystem	NaN
licenseInfo.elapsedTime	0.009947
maxDecodingTime	**0.129162**
networkErrors	0.022833
networkInfo.carrier.mnc	-0.031805
networkInfo.type	-0.012458
position	0.126110
timestamp	-0.031551
qualityChangedCount	-0.171506
content_type	-0.027799
bufferingTime	0.044721

r = X와 Y가 함께 변하는 정도 /
X와 Y가 각각 변하는 정도

$0.7 < |r| \leq 1$: 강한 선형관계
$0.3 < |r| \leq 0.7$: 뚜렷한 선형관계
$0.1 < |r| \leq 0.3$: 약한 선형관계
$|r| \leq 0.1$: 거의 무시할 수 있는 선형관계

errorCode 와 다른 feature들은
거의 무시할 수 있는 선형관계

데이터에 대한 배경지식을
기반으로 manual하게 feature
selection 진행

https://www.scienceall.com/%EC%83%81%EA%B4%80%EA%B3%84%EC%88%98coefficient-of-correlation/

Data Preprocessing

Data Preprocessing

Data preprocessing ?

1) Raw Data를 모델이 이해할 수 있는 (학습에 사용할 수 있는) 형식으로 바꿔주는 데이터마이닝 기법

2) 현실의 데이터는 불완전하고 에러를 많이 포함하며 불연속적인 부분이 존재하기 때문에 이런 이슈를 해결하는 과정이 필요

3) 결측치 처리(삭제, 다른값으로 대체, 예측값 삽입) ,이상치 처리(삭제, 다른값으로 대체, 리샘플링, 케이스 분리 분석), Transforming(기존의 데이터로 다른 변수 제작) 등

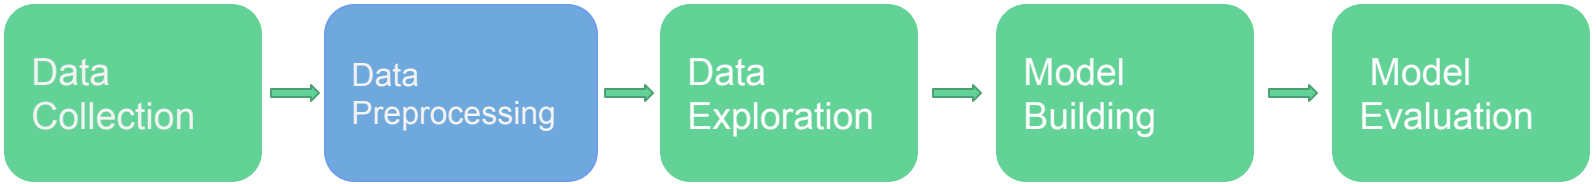

Data Preprocessing

Categorical value ➞ label encoding (범주형 자료 라벨링)

```
In [8]: df['device'].value_counts()

Out[8]: Android 8.0.0    193
        Android 5.0.2     31
        Android 8.1.0     30
        Android 6.0.1     24
        Android 7.0       22
        Android 7.1.2      8
        Android 5.0        6
        Android 6.0        5
        Android 5.0.1      2
        Android 7.1.1      2
        Android 5.1.1      1
        Name: device, dtype: int64
```

```
In [18]: le_divice = preprocessing.LabelEncoder()
df['device'] = le_divice.fit_transform(df['device'].astype(str))
print('encoding 된 device : \n',  le_divice.classes_)
print('encoding 후 device 값 : \n' ,df['device'].value_counts())

encoding 된 device :
 ['Android 5.0' 'Android 5.0.1' 'Android 5.0.2' 'Android 5.1.1'
 'Android 6.0' 'Android 6.0.1' 'Android 7.0' 'Android 7.1.1'
 'Android 7.1.2' 'Android 8.0.0' 'Android 8.1.0' 'None']
encoding 후 device 값 :
 9     193
2       31
11      30
10      30
5       24
6       22
8        8
0        6
4        5
7        2
1        2
3        1
Name: device, dtype: int64
```

device, networkInfo.type (LTE, None, WIFI), licenseInfo.drmSystem(데이터 유무) 를 위와 같은 방법으로 처리함

Data Preprocessing

Data counting (json row 갯수 count)

```
In [21]: df['qualityChanged'].iloc[17]

Out[21]: [{'bandwidth': 431581, 'position': 0, 'timestamp': 1541721419},
          {'bandwidth': 2725906, 'position': 10076, 'timestamp': 1541721420}]
```

1

2

```
In [18]: df['qualityChangedCount'] = None

In [19]: for row, val in enumerate(df['qualityChanged']):
             if isinstance(val, float):
                 df['qualityChangedCount'][row] = 0
             else:
                 df['qualityChangedCount'][row] = len(val)

/home/centos/anaconda3/envs/dev/lib/python3.5/site-package
A value is trying to be set on a copy of a slice from a Da

See the caveats in the documentation: http://pandas.pydata
us-copy
  """

In [20]: df['qualityChangedCount'].value_counts()

Out[20]: 0    202
         1     96
         2     56
         Name: qualityChangedCount, dtype: int64
```

Event 가 발생한 횟수를 반영하기 위해 counting 방법을 이용
frameDropped 와 qualityChanged 를 위와 같은 방법으로 처리함

Data Preprocessing

Extract valid part (유효한 부분만 추출)

```
In [111]: qoe_ended['contentUrl'].head(3).tolist()

Out[111]: ['http://abc-streaming.akamaized.net/g/mpd/d/main/video/1065/10656340/10656340.mpd?p=80&cf=1541728796&e=1541804396
&h=c3d0063630dc0d664be09c31a08e0b97',
 'http://abc-streaming.akamaized.net/g/mpd/d/main/video/1065/10656983/10656983.mpd?p=80&cf=1541728803&e=1541804403
&h=32fc8d807a3afac2f701ac1f0f671d8f',
 'http://abc-streaming.akamaized.net/g/mpd/d/main/video/1065/10656983/10656983.mpd?p=80&cf=1541728808&e=1541804408
&h=d7d7ade43a2d010733545c602b44e7c1']
```

```
In [25]: le_content = preprocessing.LabelEncoder()
         df['content_type'] = le_content.fit_transform(df['content_type'].astype(str))
         le_content.classes_

Out[25]: array(['contents', 'video'], dtype=object)

In [26]: df['content_type'].value_counts()

Out[26]: 1    237
         0     87
         Name: content_type, dtype: int64
```

contentUrl 에서 content_type 추출 후 label encoding

Data Preprocessing

Sum of data

```
In [118]: qoe_updated[qoe_updated.index==42159755583668]['bufferings'].tolist()
Out[118]: [[{'currentTime': 1541719621, 'duration': 120},
            {'currentTime': 1541719621, 'duration': 975}]]
```

```
In [36]: df['bufferingTime'].head(10)
Out[36]: timestamp
         2018-11-08 23:08:53      31
         2018-11-08 23:22:38       0
         2018-11-08 23:20:46       0
         2018-11-08 23:44:54       0
         2018-11-08 23:09:01    1528
         2018-11-08 23:56:49       0
         2018-11-08 23:21:16       0
         2018-11-08 23:22:43       0
         2018-11-08 23:48:10       0
         2018-11-08 23:31:47       0
         Name: bufferingTime, dtype: int64
```

bufferings 의 duration 값만 추출한 후 더하여 total duration값을 반영함

Decision Tree & Random Forest

Machine Learning?

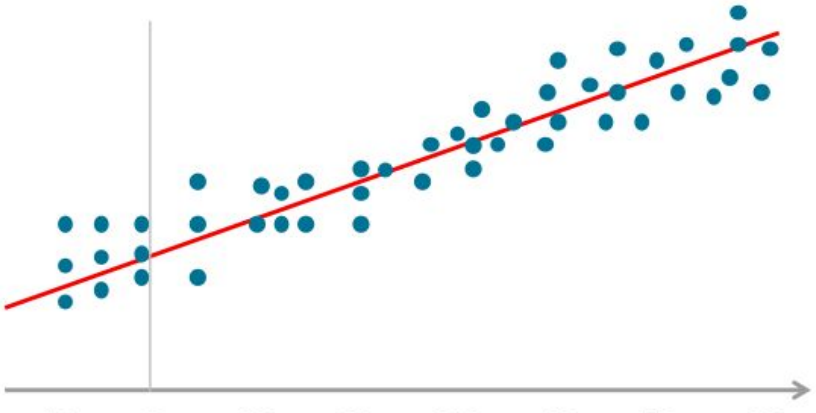

Linear Regression

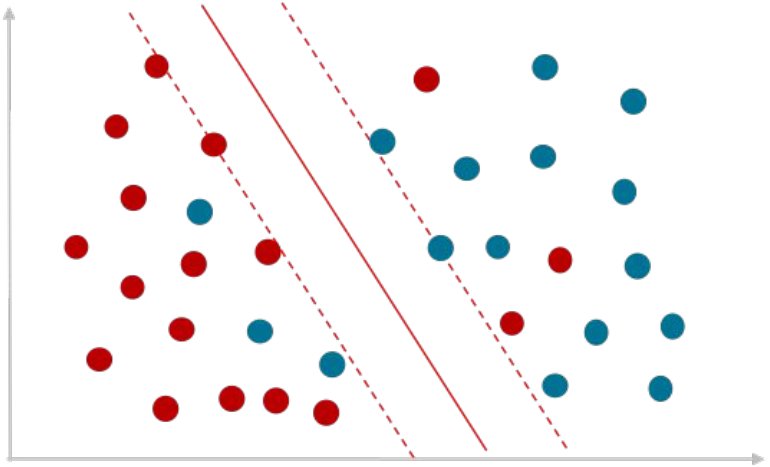

Classification

과거/기존의 데이터를 **학습**하여 **미래/새로운**의 데이터를 **예측**

출처: Learn about data lakes, machine learning & more innovations (https://goo.gl/VeUbEi)

Machine Learning Step

1. 문제 정의
2. Train Data 수집
3. Exploratory Data Analysis – Cleaning & Preprocessing
4. Data 분류 – Labeling
5. 모델 설계
6. 모델 학습
7. 성능 Test

참조: [머신러닝] 의사결정트리 (Decision Tree) 알고리즘 쉽게 이해하기 by 허민석 (https://goo.gl/8e9DqW)

Decision Tree

Q. 겨울에 찍은 가족사진은?










출처: 구글 (google.com) / 참조: [머신러닝] 의사결정트리 (Decision Tree) 알고리즘 쉽게 이해하기 by 허민석 (https://goo.gl/8e9DqW)

Decision Tree




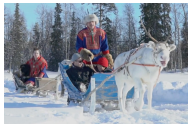


캐릭터?	겨울?	여러 명?	겨울 가족 사진
1	1	1	**0**
0	0	1	**0**
1	0	1	**0**
0	1	1	1
0	0	1	**0**





캐릭터?	겨울?	여러 명?	겨울 가족 사진
0	1	1	1
1	1	1	**0**
1	1	0	**0**
0	1	0	**0**
1	1	1	**0**

참조: [머신러닝] 의사결정트리 (Decision Tree) 알고리즘 쉽게 이해하기 by 허민석 (https://goo.gl/8e9DqW)

Decision Tree

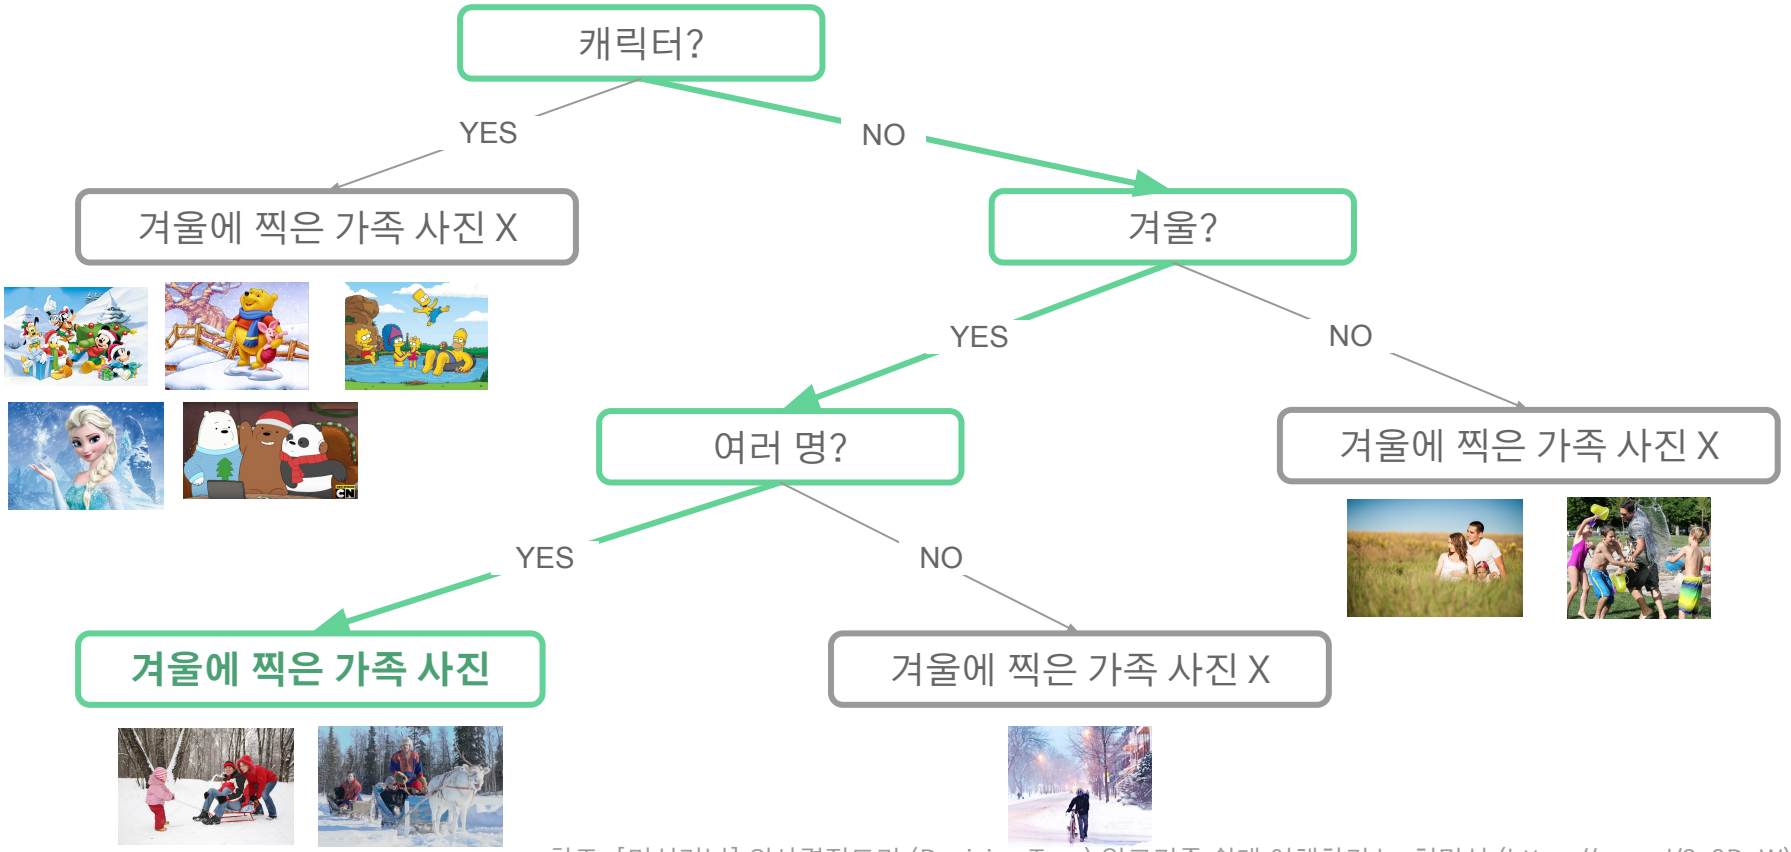

참조: [머신러닝] 의사결정트리 (Decision Tree) 알고리즘 쉽게 이해하기 by 허민석 (https://goo.gl/8e9DqW)

Decision Tree

Information Gain

= Base Entropy - New Entropy

Information Gain이 높을 수록 효율적인 Split Option

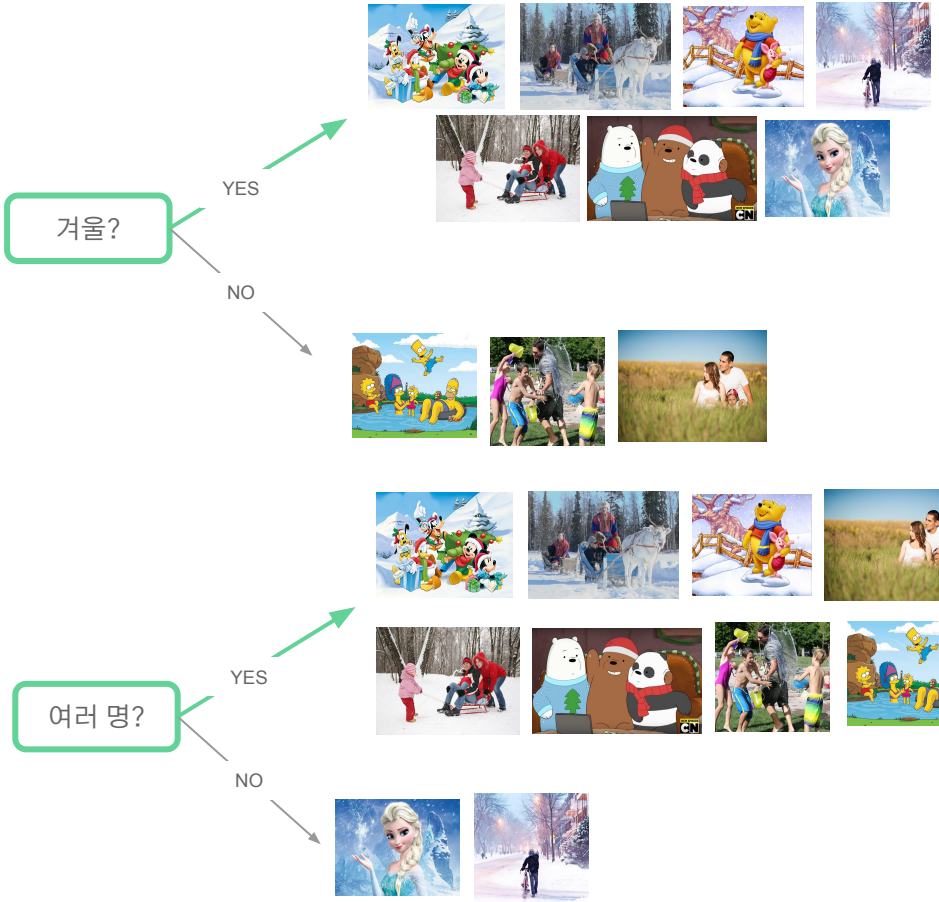

* 캐릭터 I.G = 10 – 5 = **5**

* 겨울 I.G = 10 – 7 = 3

* 여러 명 I.G = 10 – 8 = 2

참조: [머신러닝] 의사결정트리 (Decision Tree) 알고리즘 쉽게 이해하기 by 허민석 (https://goo.gl/8e9DqW)

Decision Tree

캐릭터?	겨울?	여러 명?
0	1	1
1	1	1
0	0	1

INPUT

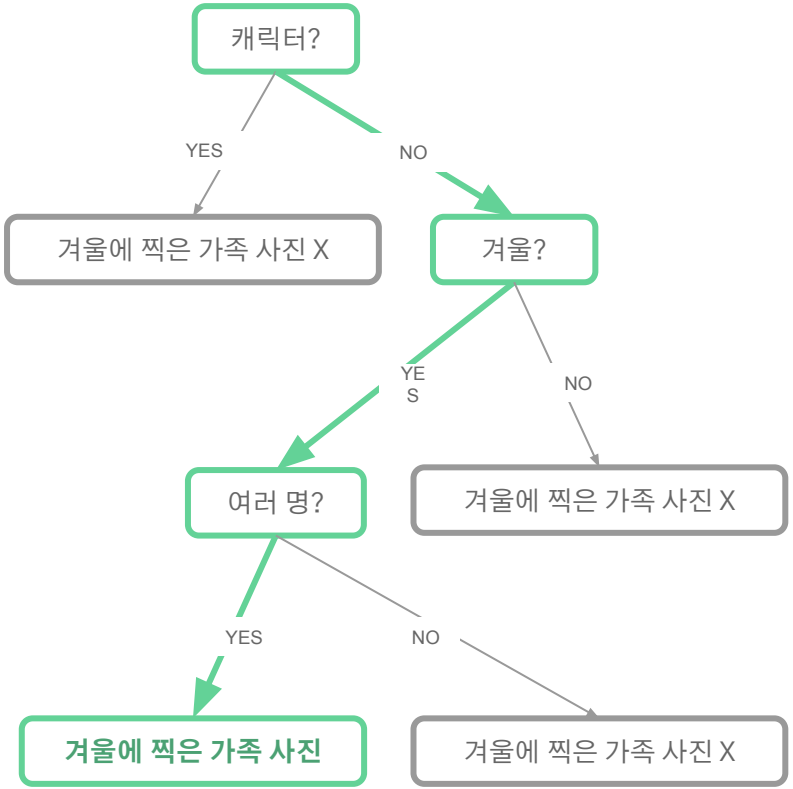

참조: [머신러닝] 의사결정트리 (Decision Tree) 알고리즘 쉽게 이해하기 by 허민석 (https://goo.gl/8e9DqW)

Random Forest

Tree

Forest

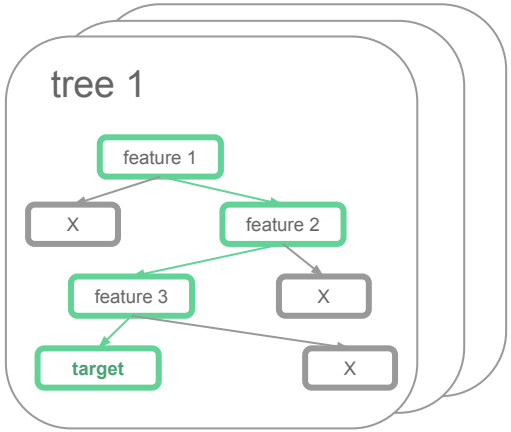

Decision Tree

....

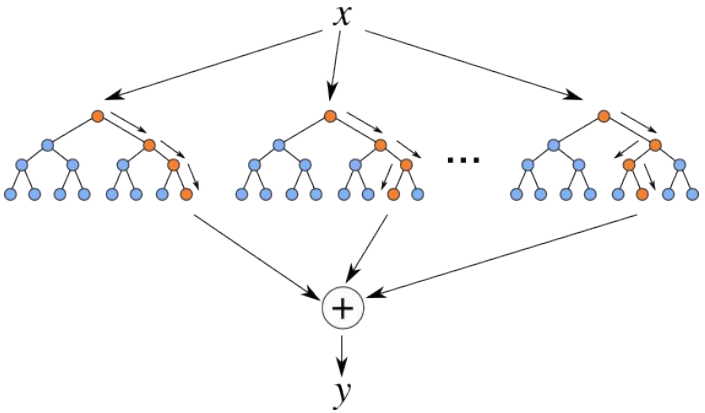

Random Forest

Random Forest

겨울에 찍은 가족사진인지 구분할 수 있는 요소

눈의 여부
옷의 두께
모자, 장갑 등의 겨울 소품
아이의 여부
야외, 실내
인원 수
사진 속 인물들의 평균 연령
성별 비율
.
.
.

Radom

Tree 생성

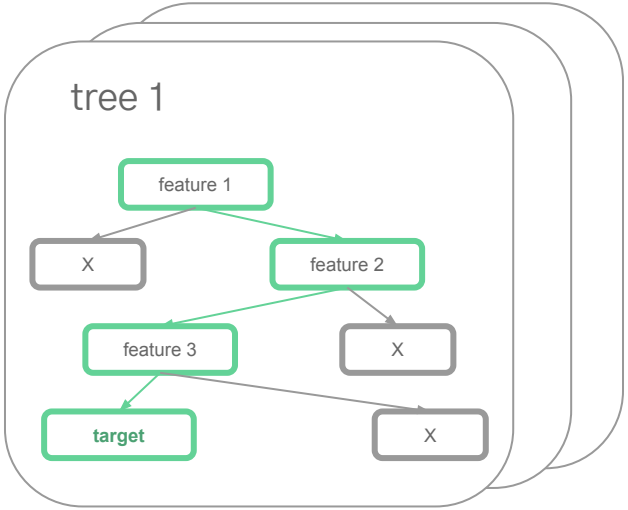

참조: 군중은 똑똑하다—Random Forest (https://goo.gl/RRaoc2)

Random Forest

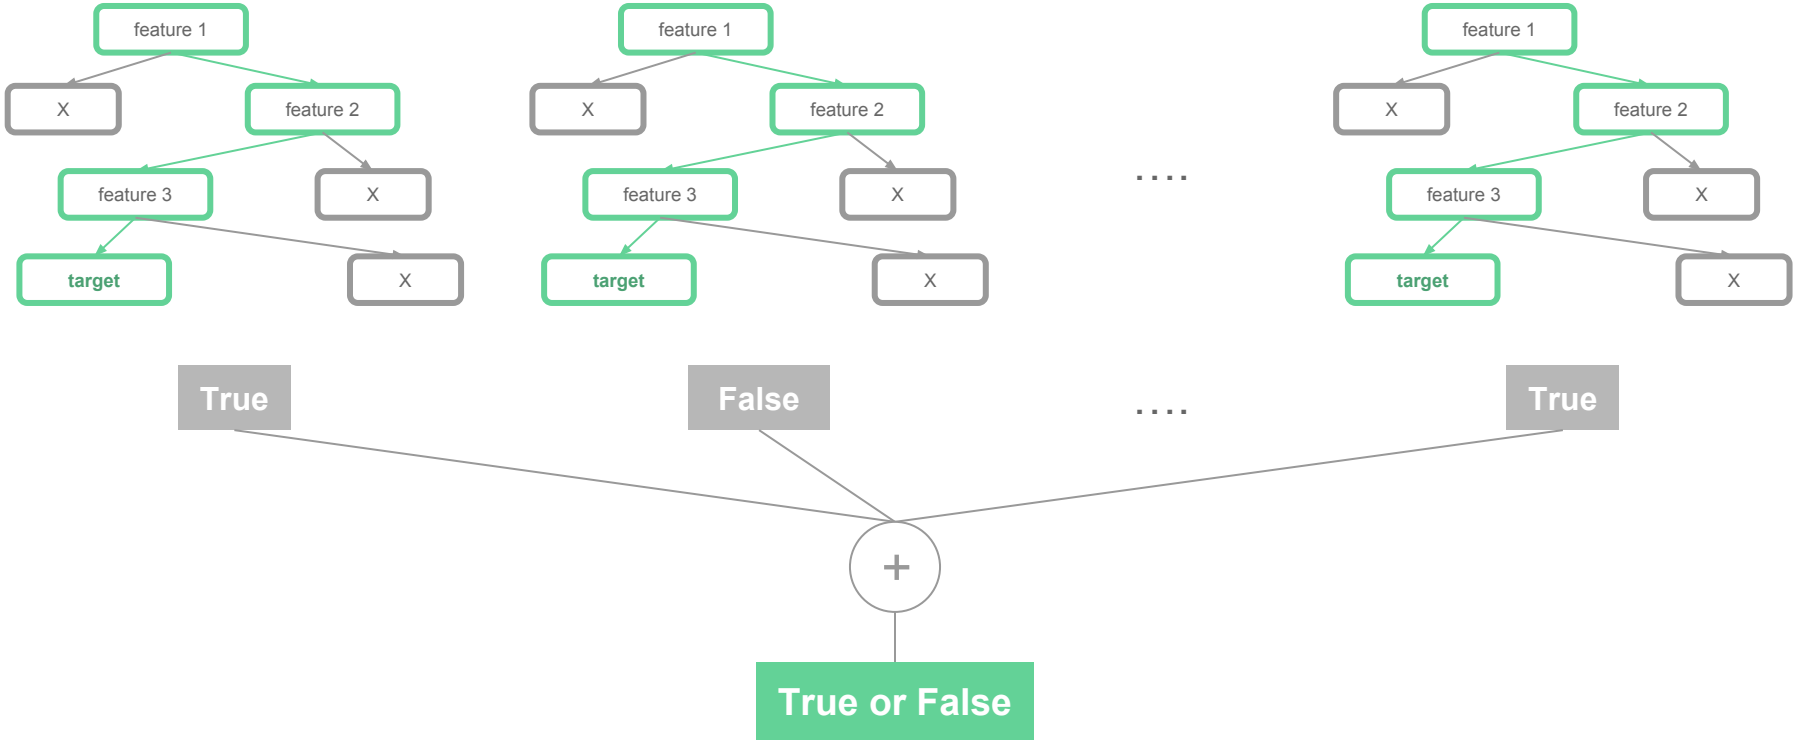

참조: 군중은 똑똑하다—Random Forest (https://goo.gl/RRaoc2)

Experiments & Reports

Performance Evaluation Metrics

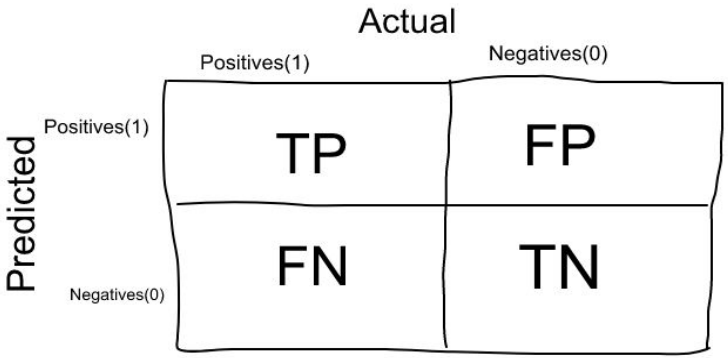

- Accuracy(정확도)

  : 전체 중 **맞춘 것**의 비율

$$\frac{TP + TN}{TP + FN + FP + TN}$$

- Precision(정밀도)

  : True라고 분류한 샘플 중의 **실제 True**의 비율

$$\frac{TP}{TP + FP}$$

- Recall(재현율)

  : 실제 True 중에 **True라고 분류한 샘플**의 비율

$$\frac{TP}{TP + FN}$$

출처: Performance Metrics for Classification problems in Machine Learning (https://goo.gl/GaWCNQ) / 참조: 분류성능평가 (https://goo.gl/Ep8SgP)

Decision Tree - Naive

- Accuracy: 0.96
- **대부분의 ErrorCode를 0으로 예측**하였기 때문에 전체 ErrorCode에 대한 Accuracy 점수는 높지만 **다른 ErrorCode 각각의 Metric 점수(Precision, Recall)는 낮음**
- Error가 아닌 데이터와 Error인 데이터의 **비율이 불균형 (Data Imbalance)**하기 때문에 전체 데이터 개수로 계산하는 Accuracy보다 Precision과 Recall 점수가 높을수록 성능이 좋은 모델

ErrorCode	Precision	Recall	Support
-101416.0	0.00	0.00	1
-100874.0	0.00	0.00	4
-100870.0	0.00	0.00	3
-100859.0	0.00	0.00	1
-100702.0	0.00	0.00	90
-2005.0	0.00	0.00	11
-1004.0	1.00	0.90	10
-1002.0	0.67	0.40	5
-38.0	0.00	0.00	53
0.0	0.96	**1.00**	3554

Resampling

- 모델의 성능을 높이기 위한 방법 중 하나
- 데이터의 timestamp 간격을 **무작위** → **일정 간격**으로 재정렬
- 데이터 resampling 후 NaN 값이 있는 시간에는 각각 앞 시간의 데이터, 최빈값, 평균값 등으로 채움

timestamp	errorCode	estimatedBandwidth	fragmentSum.bitrate
2018-11-06 02:14:03	0.0	66791384	0
2018-11-06 02:14:14	0.0	30158938	0
2018-11-06 02:14:37	0.0	80715832	106455214
2018-11-06 02:14:37	0.0	40284572	6255458
2018-11-06 02:14:40	0.0	49529664	0

Resample

timestamp	errorCode	estimatedBandwidth	fragmentSum.bitrate
2018-11-06 02:14:00	0.0	66791384.0	0.0
2018-11-06 02:14:15	0.0	66791384.0	0.0
2018-11-06 02:14:30	0.0	80715832.0	106455214.0
2018-11-06 02:14:45	0.0	104205000.0	0.0
2018-11-06 02:15:00	0.0	89998664.0	0.0

Decision Tree - 15s

- Accuracy: 0.96
- 15초 간격으로 resampling
- 15초 사이에 데이터가 **여러 개** 있을 경우,
  15초 간격의 해당 시간 데이터가 **NaN 값**일 경우
  : 시간 순으로 정렬했을 때 **가장 처음 값**

timestamp	errorCode	estimatedBandwidth	fragmentSum.bitrate
2018-11-06 02:14:03	0.0	66791384	0
2018-11-06 02:14:14	0.0	30158938	0

timestamp	errorCode	estimatedBandwidth	fragmentSum.bitrate
2018-11-06 02:14:00	0.0	66791384.0	0.0

ErrorCode	Precision	Recall	Support
-100874	0.00	0.00	1
-100859	0.00	0.00	1
-100702	0.00	0.00	51
-2005	0.00	0.00	1
-1004	0.33	1.00	1
-1002	1.00	0.50	6
-38	0.00	0.00	22
0	0.96	1.00	2114

Decision Tree & Random Forest - 10min

- Accuracy: DT – 0.75 / RF – 0.82
- 10분 간격으로 resampling
- 10분 사이에 데이터가 **여러 개** 있을 경우: **평균값** (numeric) / **최빈값** (categorical)

ErrorCode	Precision	Recall	Support
-100874.0	0.00	0.00	1
-100702.0	0.79	0.70	27
-1004.0	0.75	1.00	3
-1002.0	0.00	0.00	2
-38.0	0.70	0.93	15
0.0	0.71	0.71	7

Decision Tree

ErrorCode	Precision	Recall	Support
-100874.0	0.00	0.00	1
-100702.0	0.80	0.89	27
-1004.0	1.00	1.00	3
-1002.0	0.00	0.00	2
-38.0	0.81	0.87	15
0.0	0.83	0.71	7

Random Forest

Decision Tree & Random Forest - 15min

- Accuracy: DT – 0.676 / RF – 0.68
- 15분 간격으로 resampling
- 15분 사이에 데이터가 **여러 개** 있을 경우: **평균값** (numeric) / **최빈값** (categorical)

ErrorCode	Precision	Recall	Support
-100874.0	0.00	0.00	1
-100870.0	0.00	0.00	1
-100702.0	0.82	0.88	16
-1004.0	1.00	0.60	5
-38.0	0.40	0.86	7
0.0	1.00	0.29	7

Decision Tree

ErrorCode	Precision	Recall	Support
-100874.0	0.00	0.00	1
-100870.0	0.00	0.00	1
-100702.0	0.76	0.81	16
-1004.0	1.00	0.60	5
-38.0	0.33	0.57	7
0.0	1.00	0.71	7

Random Forest

Oversampling - SMOTE

- SMOTE(Synthetic Minority Over-sampling Technique)
- **데이터 불균형 (Data Imbalance)** 문제를 해결하기 위한 방법 중 하나

> " The minority class is over-sampled by taking each minority class sample and **introducing synthetic examples along the line segments joining any/all of the *k* minority class nearest neighbors.** "
>
> <SMOTE: Synthetic Minority Over-sampling Technique> 중 일부

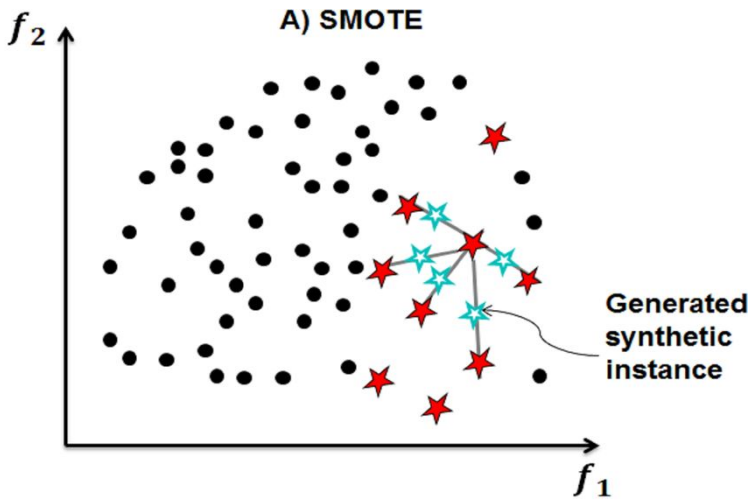

출처: (https://goo.gl/2pkfza) / 참조: <SMOTE: Synthetic Minority Over-sampling Technique> (https://goo.gl/DVYsDb)

Decision Tree & Random Forest - 15s

- Accuracy: DT – 0.631 (10000 iter) / RF – 0.98
- train dataset 의 Y data 중 **가장 많은 수의 데이터** (ErrorCode: 0 / 7375개) 기준으로 SMOTE

ErrorCode	Precision	Recall	Support
-100702	0.23	0.41	63
-2005.0	0.01	1.00	3
-1004.0	1.00	0.50	2
-1002.0	0.11	0.33	3
-38.0	0.03	0.61	36
0.0	1.00	0.63	3184

Decision Tree

ErrorCode	Precision	Recall	Support
-100702	0.76	0.90	63
-2005.0	0.50	0.33	3
-1004.0	1.00	0.50	2
-1002.0	0.75	1.00	3
-38.0	0.38	0.36	36
0.0	0.99	0.99	3184

Random Forest

Conclusion

- 2일 치의 데이터로만 학습하여 ErrorCode의 패턴 트렌드 및 error 발생 시간 예측 불가
- QoE Data 와 ErrorCode간의 상관관계가 뚜렷한 양상을 띄지 않음
- feature selection을 manual하게 진행하여 신뢰성 하락

- 충분한 컴퓨팅 자원과 실험 조건(데이터의 개수, feature 등) 하에 딥러닝 모델(RNN, LSTM, GRU 등)을 활용하여 학습한다면 ErrorCode의 패턴 트렌드 파악 및 발생 확률을 실시간으로 예측할 수 있는 모델 구축 가능

Q&A

Thank You :)